

# BPR: Bayesian Personalized Ranking

Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, Lars  
Schmidt-Thieme

Presenter: 山田倫太郎

February 17, 2020

# 研究背景

推薦システムにおいて個人の嗜好を予測することは重要

大別すると 2 種類のデータが考えられる

- Explicit feedback
  - ▶ ユーザの興味が明示的に与えられているデータ  
例) Amazon の☆や facebook の「いいね」
- **Implicit feedback**
  - ▶ ユーザの興味が明示的に与えられてないデータ  
例) 購入履歴や閲覧履歴

## 目標

Implicit feedback を元にユーザの嗜好をランキングする

# 従来法


閲覧されたか否かを  $\{0,1\}$  のラベルで表現

$u$ : ユーザ

$i$ : アイテム

+: 閲覧済み

?: 未閲覧



## 問題点

未閲覧のデータ中で以下を区別できない


- ユーザの興味がないもの
- ユーザの興味があるが閲覧していないもの

# 提案手法

## 方針

ユーザの選好関係をモデル化する

仮定：閲覧済みアイテムの興味 > 未閲覧アイテムの興味



# 記法

- $U$ : ユーザの全体集合
- $I$ : アイテムの全体集合
- $U_i^+$ : アイテム  $i$  を閲覧したユーザの全体集合
- $I_u^+$ : ユーザ  $u$  が閲覧したアイテムの全体集合
- $D_s$ : フィードバックが得られているデータセット
  - ▶  $D_s := \{(u, i, j) \mid i \in I_u^+ \wedge j \in I \setminus I_u^+\}$
- $>_u$ : ユーザ  $u$  の嗜好情報
- $\Theta$ : モデルパラメータ
- $x_{ui}$ : ユーザ  $u$  のアイテム  $i$  の選好度合い

$x_{ui}$  は推論モデルによって既定される値なのでパラメータ  $\Theta$  に依存

$D_s$  よりパラメータ  $\Theta$  を導出したいので  $p(\Theta \mid D_s)$  を最適化

# モデリング

ベイズの定理より次の式が導かれる：

$$p(\Theta \mid D_s) \propto p(D_s \mid \Theta)p(\Theta)$$

ユーザ, アイテムの好みが独立であると仮定し, 尤度を以下で定める：

$$\prod_{(u,i,j) \in D_s} p(i >_u j \mid \Theta)$$

ここでシグモイド関数を  $\sigma$  として：

$$p(i >_u j \mid \Theta) := \sigma(\hat{x}_{ui} - \hat{x}_{uj})$$

## 目的関数: BPR-Opt

- 事前分布  $p(\Theta)$  は正規分布  $N(0, \lambda_{\Theta} I)$  とする
- MAP 推定を行う

$$\begin{aligned}\hat{\Theta} &= \arg \max_{\Theta} \ln p(\Theta \mid D_s) \\ &= \arg \max_{\Theta} \ln p(D_s \mid \Theta) p(\Theta) \\ &= \arg \max_{\Theta} \ln \prod_{(u,i,j) \in D_s} \sigma(\hat{x}_{ui} - \hat{x}_{uj}) p(\Theta)\end{aligned}$$

- 以下の目的関数を最大化する

$$\text{BPR-Opt} := \sum_{(u,i,j) \in D_s} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) - \frac{1}{2\lambda_{\Theta}} \|\Theta\|^2$$

## 目的関数: BPR-Opt

- BPR-Opt を微分すると

$$\begin{aligned}\frac{\partial \text{BPR-Opt}}{\partial \Theta} &= \sum_{(u,i,j) \in D_s} \frac{\partial}{\partial \Theta} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) - \frac{1}{2\lambda_{\Theta}} \frac{\partial}{\partial \Theta} \|\Theta\|^2 \\ &= \frac{-e^{\hat{x}_{ui} - \hat{x}_{uj}}}{1 + e^{\hat{x}_{ui} - \hat{x}_{uj}}} \cdot \frac{\partial}{\partial \Theta} (\hat{x}_{ui} - \hat{x}_{uj}) - \frac{\Theta}{\lambda_{\Theta}}\end{aligned}$$

- $(u, i, j) \in D_s$  は膨大となりやすいので確率的勾配法を用いて解く



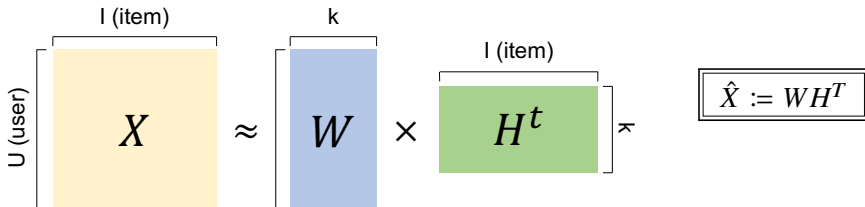
# 学習アルゴリズム: Learn-BPR

```
1: procedure LEARN-BPR( $D_s, \Theta$ )
2:   initialize  $\Theta$ 
3:   repeat
4:     draw (u,i,j) from  $D_s$ 
5:      $\Theta \leftarrow \Theta + \alpha \left( \frac{-e^{\hat{x}_{ui} - \hat{x}_{uj}}}{1 + e^{\hat{x}_{ui} - \hat{x}_{uj}}} \cdot \frac{\partial}{\partial \Theta}(\hat{x}_{ui} - \hat{x}_{uj}) - \frac{\Theta}{\lambda_{\Theta}} \right)$ 
6:   until convergence
7:   return  $\hat{\Theta}$ 
8: end procedure
```

- $\frac{\partial}{\partial \Theta}(\hat{x}_{ui} - \hat{x}_{uj})$  については次に示す

## $x_{ui}$ の具体例 1 : Matrix Factorization

次元削減を行って  $\hat{x}_{ui}$  を推定する



A diagram illustrating matrix factorization. On the left, a yellow square matrix  $X$  is labeled with 'U (user)' on its left and 'I (item)' on its top. This matrix is approximately equal to the product of two matrices: a blue rectangular matrix  $W$  and a green rectangular matrix  $H^t$ . The matrix  $W$  is labeled with 'k' on its top, and the matrix  $H^t$  is labeled with 'I (item)' on its top and 'k' on its right. To the right of the product is a double-bordered box containing the equation  $\hat{X} := WH^T$ .

$$\begin{matrix} \text{U (user)} \\ \left[ \begin{array}{c} \text{I (item)} \\ X \end{array} \right] \approx \left[ \begin{array}{c} k \\ W \end{array} \right] \times \left[ \begin{array}{c} \text{I (item)} \\ H^t \end{array} \right] \begin{matrix} k \end{matrix} \end{matrix} \quad \boxed{\hat{X} := WH^T}$$

$$\begin{aligned} \hat{x}_{ui} &= \langle w_u, h_i \rangle \\ &= \sum_{f=1}^k w_{uf} \cdot h_{if} \end{aligned} \quad \frac{\partial}{\partial \Theta} (\hat{x}_{ui} - \hat{x}_{uj}) = \begin{cases} (h_{if} - h_{jf}) & \text{if } \theta = w_{uf} \\ w_{uf} & \text{if } \theta = h_{if} \\ -w_{uf} & \text{if } \theta = h_{jf} \\ 0 & \text{else} \end{cases}$$

## $x_{ui}$ の具体例 2 : Adaptive k Nearest Neighbor

観測済みアイテムとの類似度をもとに  $\hat{x}_{ui}$  を推定する

$$\hat{x}_{ui} = \sum_{i \in I_u^+ \wedge l \neq i} c_{il}$$

$$\frac{\partial}{\partial \Theta}(\hat{x}_{ui} - \hat{x}_{uj}) = \begin{cases} +1 & \text{if } \theta \in \{c_{il}, c_{li}\} \wedge l \in I_u^+ \wedge l \neq i \\ -1 & \text{if } \theta \in \{c_{jl}, c_{lj}\} \wedge l \in I_u^+ \wedge l \neq j \\ 0 & \text{else} \end{cases}$$

# 実験

- ① Rossmann オンラインショップの購入履歴から、ユーザが次に買いたい品物を予測
- ② Netflix の過去の映画の評価履歴をもとに、与えられた映画に評価を行うかを予測

	ユーザー（人）	アイテム（個）	観測済み（個）
Rossmann	10,000	4,000	436,612
Netflix	10,000	5,000	565,738


- ROC 曲線の AUC を評価

# 比較手法

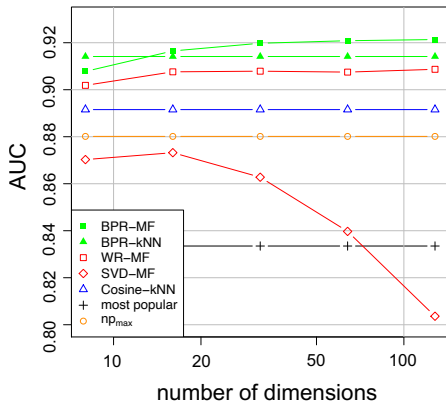
- **BPR-MF**
  - ▶ パラメータの更新に BPR-Opt を用いた MF
- **BPR-kNN**
  - ▶ パラメータの更新に BPR-Opt を用いた k 近傍
- SVD-MF
  - ▶ SVD（特異値分解）を適応したもの
- WR-MF
  - ▶ SVD（特異値分解）の過学習を抑えるように改良したもの
- Cosine-kNN
  - ▶ コサイン類似度を用いた k 近傍法
- most popular
  - ▶ 学習データの中で最も人気のものを推薦する
- $np_{\max}$ 
  - ▶ テストデータの中で最も人気のものを推薦する

# 結果

## Online shopping: Rossmann



## Video Rental: Netflix



実験において提案手法が他のモデルよりも優れた結果を示した

# まとめ

## BPR の手法

- 閲覧済みアイテムは未閲覧アイテムより興味があると仮定を置く
- ユーザのアイテム同士の選好関係をモデル化する
- パラメータ最適化に確率的勾配法を用いる

## 結果

BPR によるパラメータ最適化が他のモデルよりも優れている